1 Langages

Afin de situer ce cours, et en guise de rappels, nous nous contenterons de donner quelques définitions sensées être connues et vues dans le cadre des cours abordant les langages réguliers (ou rationnels) et les automates d'états finis.

1 Alphabets, mots, langages

1.1 Définitions

Alphabet

Un *alphabet* (ou *vocabulaire*) est un ensemble V de symboles (appelés parfois *lettres*).

Mot

Un *mot* (sur V) est une suite finie (éventuellement vide) de symboles (de V). Un mot u de longueur n sera noté $u = u_1...u_n$.
Le mot de longueur 0, appelé *mot vide*, est noté ε.

Langages

Un *langage* (sur V) est un ensemble de mots (sur V).
On note V^* le langage de tous les mots possibles sur V.
Un langage L sur V est donc un sous ensemble de V^* ($L \subseteq A^*$).

1.2 Exemples

Exemple E1.1:

Soit l'alphabet $V = \{a, b, c\}$. a, ab et bc sont des mots sur l'alphabet V. $\{ab, bc\}$ est un langage.
$\emptyset$ est le langage vide et $\{\varepsilon\}$ est le langage (non vide) contenant le mot vide.

Exemple E1.2:

Attention, lorsqu'on travaille avec des langages formels, on se simplifie la vie, mais il ne faut pas croire qu'un symbole (au sens des langages formels) est forcément une lettre (au sens général) ou un caractère (au sens informatique). En fait, ce ne sera généralement pas le cas. Par exemple :
Soit l'alphabet $V = \{(,), true, if, then, else, action\}$.
$u = if$ $(true)$ $then$ $action$ est un mot de longueur 6 sur cet alphabet. $v = then$) if $else$ est aussi un mot sur cet alphabet.
Le langage de toutes les instructions conditionnelles (simplifiées) est un langage sur cet alphabet (un ensemble de mots). Il peut être infini et contiendra vraisemblablement u mais pas v.

1.3 Exercices

Exercice E1.3:

Soit $V = \{a, b\}$ un alphabet.
Donnez tous les mots de longueur 3 sur V.
Donnez en extension le langage $L = \{u \in V^* | u$ est de longueur ≤ 4 et contient autant de a que de $b\}$.

1.4 Notations (abus de –)

Vous aurez noté que a est parfois utilisé pour représenter une *lettre* ($a \in V$) et d'autres fois pour représenter un *mot* (de longueur 1, $a \in V^*$). Il sera même parfois utilisé par abus de notation pour représenter le langage ne contenant que le mot a (a dénotera le langage $\{a\}$, $a \subseteq V^*$).
Il en est de même pour ε qui sera parfois utilisé pour dénoter le mot vide ou le langage réduit au mot vide.
Cet abus de notation peut entraîner des surprises pour l'étudiant qui n'est pas attentif ou qui ne maîtrise pas les concepts fondamentaux du cours. Je vous conseille donc de vous entraîner et de bien réviser vos concepts. Selon le contexte, vous serez toujours à même de savoir de quoi on parle... avec l'habitude.

2 Opérations sur les mots et sur les langages

2.1 Concaténation de mots, de langages

Sur les mots

Soient $u = u_1...u_n$ et $v = v_1...v_p$.
La concaténation (ou produit de concaténation) de u et de v est le mot $w = u_1...u_nv_1...v_p$.
On notera $w = u.v$ ou plus simplement $w = uv$.
On remarque que la concaténation est associative ($(uv)w = u(vw) = uvw$) et que ε en est l'élément neutre ($u.\varepsilon = \varepsilon.u = u$).

Extension sur les langages

Soient L et M deux langages, $L.M = \{w = u.v \,|\, u \in L \text{ et } v \in M\}$.
On remarque que la concaténation sur les langages est aussi associative, que ε en est l'élément neutre ($L.\varepsilon = \varepsilon.L = L$) et que $\emptyset$ en est l'élément absorbant ($L.\emptyset = \emptyset.L = \emptyset$).

2.2 Opérations sur les langages

Soient L et M des langages sur l'alphabet V.

Somme $L + M = L \cup M = \{w | w \in L \text{ ou } w \in M\}$.

Intersection $L \cap M = \{w | w \in L \text{ et } w \in M\}$.

Différence $L - M = \{w | w \in L \text{ et } w \notin M\}$.

Complément $L^c = \{w \in V^* | w \notin L\}$.

La somme ensembliste peut être généralisée : $\sum_{i=1}^{n} L_i = L_1 + L_2 + ... + L_n$

2.3 Puissance

La puissance $L^i \subseteq V^*$ de L est définie pour tout naturel i par la récurrence :
- $L^0 = \varepsilon$
- $L^{i+1} = L^i.L$, pour tout i

Ainsi $L^2 = L.L = \{uv | u \in L \text{ et } v \in L\}$.
Attention : ne confondez pas L^2 avec $\{u.u | u \in L\}$.
Dans le cas très simple où $L = a$, $L^i = a^i$ est réduit au seul mot de longueur i et constitué uniquement de a. Ainsi $a^5 = aaaaa$.
On donne quelques propriétés utiles des puissances :
- $L^1 = L$
- $L^iL^j = L^{i+j}$
- $LL^i = L^iL = L^{i+1}$
- $(\varepsilon + L)^k = \sum_{0 \leq i \leq k} L^i$

2.4 Itération

L'itération de L est $L^* = \sum_{i \geq 0} L^i$.
L'itération est aussi appelée *fermeture de Kleene*.
Remarque : Vous devriez maintenant comprendre pourquoi l'ensemble des mots sur V s'appelle V^*...

On donne quelques propriétés intéressantes de l'itération :
- $\emptyset^* = \varepsilon$
- $\varepsilon^* = \varepsilon$
- $L^*L^* = L^{**} = L^*$
- $LL^* = L^*L = \begin{cases} L^* - \varepsilon \text{ si } \varepsilon \notin L \\ L^* \text{ si } \varepsilon \in L \end{cases}$
- $L^* = \varepsilon + LL^*$

2.5 Homomorphismes

Soient A et B deux alphabets. On se donne une application $h : A \to B^*$ (une application qui associe une lettre de A à un mot de B). Cette application définit l'homomorphisme de mots $h^m : A^* \to B^*$ par la récurrence suivante :
- $h^m(\varepsilon) = \varepsilon$
- $h^m(a.u) = h(a).h^m(u)$

Note : pour simplifier l'écriture, nous utiliserons indistinctement h pour représenter à la fois l'application sur les lettres (h ci dessus) et l'homomorphisme de mot (h^m ci dessus).

On peut aussi étendre l'homomorphisme à un langage L : $h(L) = \{h(u)|u \in L\} = \{v|(\exists u \in L)\ v = h(u)\}$.

Les homomorphismes sont souvent utilisés pour simplifier la rédaction d'une preuve portant sur des mots ou des langages.

2.6 Divisions à droite et à gauche

Division de mots

Soit u et v des mots de V^* et a une lettre de V.

On définie les divisions à droite et à gauche de la manière suivante :

Division à droite $u/v = w$ si $w.v = u$.
C'est le mot u auquel on a enlevé v à droite. (Exemples : $ababc/bc = aba$ et $ababc/ab$ non défini).

Division à gauche $u\backslash v = w$ si $v.w = u$.
C'est le mot u auquel on a enlevé v à gauche. (Exemples : $ababc\backslash ab = abc$ et $ababc\backslash bc$ non défini).

Division d'un langage par un mot

L'utilisation principale des divisions droite et gauche se fait en divisant un langage par un mot. C'est la base d'une des méthodes les plus connues de calcul d'un automate d'état fini déterministe minimal pour un langage rationnel [1].

Soit L un langage sur V et v un mot de V^*.

Division à droite $L/v = \{w \mid \exists u \in L\ w = u/v\}$.

Division à gauche $L\backslash v = \{w \mid \exists u \in L\ w = u\backslash v\}$.

Quelques propriétés de la division On pourra vérifier les propriétés suivantes :
- $\emptyset\backslash a = \emptyset$
- $\varepsilon\backslash a = \emptyset$
- $(L + M)\backslash a = L\backslash a + M\backslash a$
- $(LM)\backslash a = \begin{cases} L\backslash a\ .\ M \\ +\ M\backslash a \text{ si } \varepsilon \in L \end{cases}$
- $L^*\backslash a = L\backslash a\ .\ L^*$

Division de langages

Soient L et M des langages sur V.

Division à droite $L/M = \{w \mid (\exists u \in L)\ (\exists v \in M)\ w = u/v\}$.

Division à gauche $L\backslash M = \{w \mid (\exists u \in L)\ (\exists v \in M)\ w = u\backslash v\}$.

1. Si vous n'arrivez pas à décrypter un seul mot de cette phrase, c'est que vous n'avez pas les prérequis du cours. Foncez sur un cours d'automates et langages !

Exemples

Soit $L = \{ab, bb, ca\}$,
- $L/b = \{a, b\}$ et $L/a = \{c\}$.
- $L\backslash b = \{b\}$ et $L\backslash a = \{b\}$.

3 Équations algébriques sur les langages

Les opérations de somme et produit sur les langages vérifient toutes les bonnes propriétés additives et multiplicatives et nous permettent donc d'écrire des équations algébriques sur les langages.
On peut donc écrire des équations sur les langages, comme par exemple, $X = AB + C$, ce qui signifie qu'on peut obtenir le langage X en concaténant les mots de A et de B et en y ajoutant ceux de C.
On peut aussi écrire une équation de la forme $X = AX + B$. Les solutions de cette équation seront tous les langages L tels que $L = AL + B$.

3.1 Lemme d'Arden

Soient A et B des langages sur V, et (E) l'équation $X = AX + B$.

Lemme 3.1 (Lemme d'Arden)
- $L = A^*B$ est une solution de (E).
- L est la plus petite solution de (E) (si M et solution de (E), alors $L \subseteq M$)
- si $\varepsilon \notin A$, alors L est l'unique solution de (E).

Il est assez simple de voir que L est solution de l'équation. En effet : $AA^*B + B = (AA^* + \varepsilon)B = A^*B$.